INSTITUCION UNIVERSITARIA IBEROAMERICANA

INTELIGENCIA ARTIFICIAL

Actividad 4 - Métodos de aprendizaje no supervisado

Descripción de los datos

Trabajo de:

SANTIAGO DUQUE MORA

GERALDINE RÍOS

Docente:

SANDRA ISABEL RODRIGUEZ BAUTISTA

Fecha de elaboración:

9 de octubre de 2026

Continuidad y procedencia

En la Actividad 2 se trabajaron las rutas del Metro de Medellín. Esta actividad continúa el proyecto con el análisis de la demanda en ocho estaciones.

Se revisaron el portal de datos abiertos y los metadatos de afluencia del Metro. Para este ejercicio se creó una muestra simulada, ya que no se contó con un archivo verificado que reuniera estación, hora, día, lluvia y evento. El enunciado permite desarrollar una muestra de datos.

Unidad de observación y tamaño

Cada fila representa un escenario hipotético de demanda de una estación durante una franja de una hora. Son 5,000 escenarios generados con semilla 42; se retiran 27 duplicados exactos y se utilizan 4,973 filas. No existe fecha ni secuencia temporal real. El muestreo de horas y días es uniforme, no proporcional al servicio.

Estaciones: Acevedo, Estadio, Itagüí, La Estrella, Niquía, Poblado, San Antonio, San Javier.

Definición de ocupación

La variable nivel_ocupacion clasifica la demanda: baja hasta 350 pasajeros, media entre 351 y 800 y alta desde 801. Son umbrales definidos para el ejercicio; no representan el porcentaje de ocupación de los trenes.

Diccionario de datos

Campo	Tipo y significado
estacion	Texto. Una de ocho estaciones del modelo anterior.
linea	Texto. Línea A o B de referencia; San Antonio se codifica en A aunque permite transbordo.
hora	Entero, 5 a 21. Franja horaria simulada.
dia_semana	Entero, 0 lunes a 6 domingo.
es_festivo	Binario, probabilidad simulada 0,06. No consulta calendario.
lluvia	Binario, probabilidad simulada 0,25.
evento_especial	Binario, probabilidad simulada 0,05.
pasajeros	Entero ≥20. Conteo simulado por franja; no capacidad.
nivel_ocupacion	Etiqueta baja/media/alta según umbrales académicos.

Generación reproducible

La base por estación va de 280 a 560. Se multiplica por 2,4 en horas pico laborables (6–8 y 17–19), por 1,2 entre las 10 y las 16 en otros casos y por 0,55 en las restantes franjas. Un día no laborable multiplica por 0,70; lluvia por 0,86; evento por 1,45. Se incorpora ruido lognormal con sigma 0,22 y media aritmética 1. Se redondea y aplica mínimo 20. Todos estos factores son supuestos didácticos sin calibración.

generar_dataset.py conserva la fórmula y las bases de cada estación. dataset_transporte.metadata.json registra semilla, versión de NumPy y SHA-256. Ambas actividades usan exactamente el mismo CSV. La regeneración con las versiones fijadas permite verificar su integridad.

Uso en el componente

K-Means utiliza hora, no_laborable y pasajeros, estandarizados. no_laborable combina fin de semana o festivo. nivel_ocupacion no participa y su columna puede omitirse. El análisis jerárquico usa perfiles agregados por estación.

Límites de interpretación

Los resultados dependen de los supuestos de la simulación. Para aplicarlos al servicio real sería necesario trabajar con mediciones por fecha y estación y comprobar su comportamiento en otros periodos. La comparación entre escenarios con y sin lluvia es descriptiva.

Fuentes consultadas y referencia del curso

Proyecto anterior: estaciones y reglas

Metro de Medellín: transparencia y acceso a datos

Metadatos oficiales: afluencia del sistema Metro

scikit-learn: validación cruzada

scikit-learn: agrupamiento

Consulta de recursos web: 9 de octubre de 2026. Los documentos oficiales se usan como contexto y búsqueda de fuentes; no son el origen de las filas simuladas.

Lectura asignada: Palma Méndez, J. T. (2008). Inteligencia artificial: métodos, técnicas y aplicaciones. McGraw-Hill España. Capítulo 16: Técnicas de agrupamiento. Lectura pendiente de revisión.